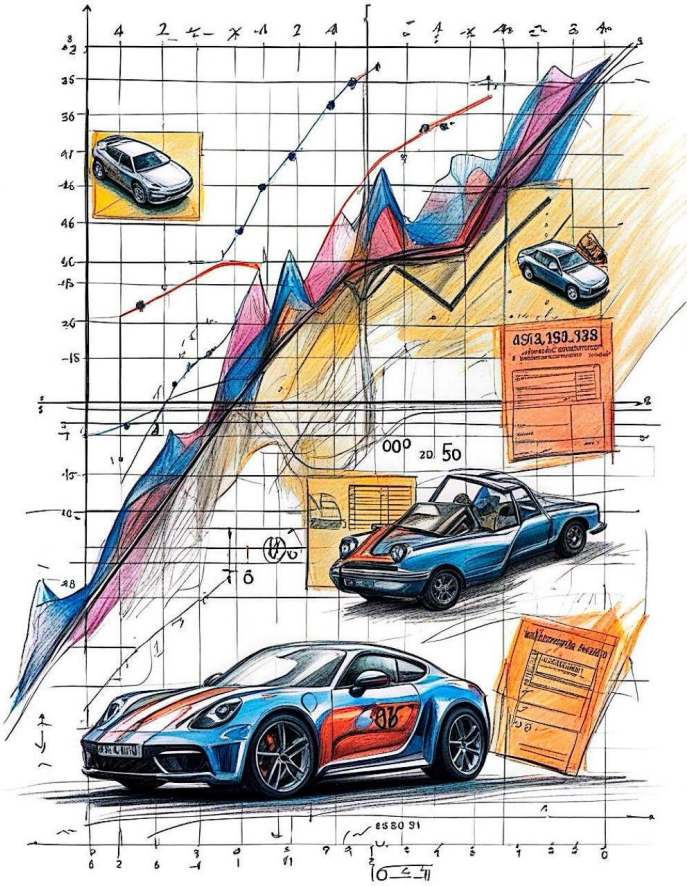
Primena uopštenih linearnih modela u neživotnom osiguranju

Maša Miladinović, Kristina Sandić, Stefan Vujadinović, Maša Lukić

Novembar 2024



Sadržaj

1 Uopšteni linearni modeli **4**
- 1.1 Osnove linearnih modela . . . 4
- 1.2 Eksponencijalna familija raspodela . . . 5
- 1.3 Uopšteni linearni modeli . . . 8
  - 1.3.1 Struktura uopštenih linearnih modela . . . 8
  - 1.3.2 Link funkcija . . . 9

2 ULM u aktuarstvu **10**
- 2.1 Izbor uopštenog linearnog modela . . . 10
- 2.2 Feature Engineering . . . 11
- 2.3 Modeliranje neprekidnih promenljivih . . . 11
  - 2.3.1 Gama regresija . . . 11
  - 2.3.2 Inverzna Gausova regresija . . . 12
- 2.4 Modeliranje diskretnih promenljivih . . . 12
  - 2.4.1 Puasonova regresija . . . 12
  - 2.4.2 Overdispersion . . . 13
  - 2.4.3 Negativna binomna regresija . . . 13
- 2.5 Zero-Inflated modeli . . . 13
  - 2.5.1 ZIP modeli - Zero-Inflated Puasonovi modeli . . . 14
  - 2.5.2 ZINB modeli - Zero-Inflated Negativna binomna . . . 14

3 Primena uopštenih linearnih modela u aktuarstvu **15**
- 3.1 Predviđanje broja odšteta . . . 16
  - 3.1.1 Puasonov model . . . 16
  - 3.1.2 Negativna binomna . . . 17
  - 3.1.3 Uvođenje interakcija . . . 19
  - 3.1.4 Zero-Inflated modeli . . . 19
- 3.2 Predviđanje vrednosti odštete . . . 20
- 3.3 Odabir odgovarajućeg modela . . . 21
  - 3.3.1 Predviđanje broja odšteta . . . 21
  - 3.3.2 Predviđanje vrednosti odštete . . . 23

4 Zaključak **25**

Sažetak

Analizirani su podaci osiguravajuće kuće sa ciljem da se ispita pogodnost primene uopštenih linearnih modela (ULM) u aktuarskim analizama podataka. Pažnja je posvećena izboru odgovarajuće raspodele. Takođe su razmatrane interakcije između prediktora kako bi se obuhvatili složeniji odnosi u podacima. Modeli su poređeni međusobno, kao i sa jednim nelinearnim modelom. Rezultati ukazuju da za date podatke uopšteni linearni modeli, konkretno sa Puasonovom i negativnom binomnom raspodelom, pružaju bolje rezultate srednje apsolutne i srednje kvadratne greške, kao i bolju interpretabilnost modela. Interakcije izmedju prediktora se nisu pokazale značajno boljim od standardnih modela.

Uvod

Analiza podataka postala je jako bitan faktor u donošenju važnih poslovnih, naučnih i društvenih odluka. Modeliranje ciljnih promennjivih pomoću velike količine podataka igra ključnu ulogu u osiguravajućim društvima, jer omogućava preciznu procenu rizika i optimizaciju polisa osiguranja. Kroz statističke metode i analize, osiguravajuća društva mogu bolje razumeti učestalost i obim osiguranih događaja, čime se omogućava preciznije oblikovanje ponuda i određivanje premija koje predstavljaju stvarne rizike.

Pre nego što nastavimo dalje, neophodno je da objasnimo neke od ključnih pojmova sa kojima ćemo se susresti u radu, a tiču se matematike neživotnog osiguranja.

Polisa za neživotno osiguranje je ugovor između osiguravajućeg društva i osiguranika, u kome se osiguravajuća kuća obavezuje da će isplatiti određenu novčanu naknadu osiguraniku za nepredvidive gubitke tokom trajanja polise, dok se osiguranik obavezuje da će uplaćivati mesečne premije.

Neživotno osiguranje predstavlja osiguranje pokretnih i nepokretnih dobara. Primera radi polisa neživotnog osiguranja može pokrivati štetu na automobilu, kući ili drugoj nepokretnoj imovini. Zapravo svako osiguranje koje ne osigurava život pojedinca je neživotno osiguranje.

Potreba za primenom statističkih metoda dolazi iz činjenice da se očekivani gubici razlikuju između polisa. Stopa nesreća nije ista za sve vlasnike polisa i očekivana šteta varira između osiguranika. Većina ljudi bi se složila da bi premija za osiguranje od požara za veliku vilu trebala biti veća od one za malu kolibu, da vozač koji je skloniji nesrećima treba da plati više za auto osiguranje. Međutim osiguravajuća kuća će težiti da izgubi starije vozače u odnosu na konkurenciju, dok će privući mlade vozače. Ovo će rezultovati gubitkom profitabilnih klijenata, a sa druge strane, dobitak klijenata koji imaju nižu cenu premije. Dolazimo do zaključka da je na tržištu najpovoljnije naplatiti fer premiju. Postavlja se pitanje: koliko naplatiti svakom pojedincu s obzirom na ukupni nivo premije. Odgovor na ovo pitanje uključuje primenu naprednih statističkih modela.

Tradicionalni linearni model, iako je široko korišćen i dobro razumljiv, ima značajna ograničenja kada su u pitanju različiti tipovi podataka i raspodele. Ovaj rad će detaljnije istražiti uopštene linearne modele, njihovu izgradnju i matematiku koja ih opravdava. Nakon teorijskog uvoda, fokusiraćemo se na primene u grani aktuarstva koja se bavi neživotnim osiguranjem, koristeći neke od uopštenih linearnih modela.

U prvom poglavlju bavićemo se teorijom uopštenih linearnih modela. Saznaćemo razliku između opšteg linearnog modela i uopštenog linearnog modela, strukturu samog modela, na koji način eksponencijalna disperziona familija utiče na uopštene linearne modele, itd.

U drugom poglavlju započinjemo priču o uopštenim linearnim modelima u neživotnom osiguranju, modeliranju neprekidnih i diskretnih promenljivih, šta je to overdisperzija i šta su zero-inflated modeli.

U trećem poglavlju ćemo vam pokazati teoriju primenjenu na pravom primeru i zaključke za odabir pravog modela za našu bazu.

1 Uopšteni linearni modeli

1.1 Osnove linearnih modela

Linearno modeliranje je jedan od ključnih alata za uspostavljanje veze između više promenljivih, sa ciljem da objasni ponašanje ciljne promenljive. Promenljive na osnovu kojih se prave linearni modeli nazivaju se prediktori. **Linearni model** opisuje odnos između zavisne promenljive Y i skupa prediktora $X_1, X_2, \ldots, X_p$ pomoću linearne kombinacije parametara. Osnovni oblik modela je:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad i = 1, \ldots, n$$

gde je:

- Y_i — zavisna promenljiva za i-tu jedinicu posmatranja,

- β_j — nepoznati parametar modela (koeficijent),
- ε_i — slučajna greška, koja se često pretpostavlja da je $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$,

Model se može zapisati i u matričnom obliku:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

gde su:

$$\mathbf{X} = \begin{pmatrix} 1 & x_{1,1} & x_{1,2} & \dots & x_{1,p} \\ 1 & x_{2,1} & x_{2,2} & \dots & x_{2,p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & x_{n,2} & \dots & x_{n,p} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- $\mathbf{Y} \in \mathbb{R}^{n\times 1}$ – vektor ciljne promenljive,
- $\mathbf{X} \in \mathbb{R}^{n\times(p+1)}$ – dizajn matrica,
- $\boldsymbol{\beta} \in \mathbb{R}^{(p+1)\times 1}$ – vektor parametara,
- $\boldsymbol{\varepsilon} \in \mathbb{R}^{n\times 1}$ – vektor grešaka.

Ovaj model pogodan je samo za analizu podataka koji imaju neprekidnu raspodelu. Ova ograničenja motivisala su istraživanje novih i fleksibilnijih pristupa analizi podataka, među kojima su uopšteni linearni modeli (ULM) jedni od najvažnijih. ULM se koriste u procenama u osiguravajućim društvima, predviđanju broja događaja u vremenskim serijama i mnogim drugim istraživanjima.

1.2 Eksponencijalna familija raspodela

Pojaviće se potreba za promenljivom disperzijom u odnosu na podatke što nas dovodi do definicije eksponencijalne familije raspodela sa raspršenjem (rasejanjem). **Eksponencijalnoj familiji raspodela sa rasejanjem** pripadaju sve raspodele za koje se funkcija gustine može prikazati u obliku gde je $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)$:

$$f(y, \boldsymbol{\theta}) = \exp\left(\frac{c(\boldsymbol{\theta})^\top T(y) - d(\boldsymbol{\theta}) + S(y)}{\phi(\tau)}\right)$$

gde je

- $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)$ — vektor parametara modela
- τ — parametar disperzije / raspršenja
- $\phi(\tau)$ — funkcija koja zavisi od τ (npr. u normalnoj raspodeli to bi bilo σ^2)

Najčešće je $\phi(\tau) = a\tau$ i u slučaju uopštenog linearnog modela podrazumevamo da je

$$f(y_i) = \exp\left(\frac{y_i\theta_i - d(\theta_i)}{a_i\tau} + c(y_i, a_i\tau)\right).$$

Razlika između eksponencijalne familije raspodela i eksponencijalne disperzione familije raspodela (eksponencijalne familije raspodela sa rasipanjem) je u parametru koji kontroliše disperziju. Disperzija nije ista za sve opservacije, već zavisi od toga kolika je njihova očekivana vrednost. Na primer, ako predviđamo broj traženih naplata štete u osiguranju automobila, osigurana lica koja retko prijavljuju štetu (vozači sa dugim

stažom) imaju manju disperziju, dok lica koja često prijavljuju štetu (mladi vozači) imaju veću disperziju. Ovakva zavisnost je česta u oblasti nezivotnog osiguranja, gde disperzija broja odšteta može značajno varirati u zavisnosti od profila osiguranika.

Kada je $\phi(\tau)$ poznato, radi se o klasičnoj eksponencijalnoj familiji raspodela. Sada ćemo pokazati da Puasonova, normalna i negativna binomna raspodela pripadaju eksponencijalnoj disperzionoj familiji raspodela gde je $\phi(\tau) = 1$.

Dokaz: Neka je $\boldsymbol{X}$ uzorak iz familije raspodela F_θ, gde je $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_p)$. Kažemo da je F_θ **jednoparametarska eksponencijalna familija raspodela** ukoliko se uzoračka raspodela može napisati u obliku

$$f(\mathbf{x}; \boldsymbol{\theta}) = \exp\left(c(\boldsymbol{\theta})T(\mathbf{x}) - d(\boldsymbol{\theta}) + S(\mathbf{x})\right)$$

- **Puasonova raspodela**: Ako X_n ima familiju Puasonovih raspodela $P(\lambda)$, onda

$$f(\mathbf{x}; \boldsymbol{\lambda}) = \prod_{i=1}^{n} \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}.$$

  Sređivanjem ovog izraza dobijamo odgovarajući oblik

$$f(\mathbf{x}; \boldsymbol{\lambda}) = e^{\sum_{i=1}^{n}(x_i \ln \lambda - \lambda - \ln(x_i!))}.$$

  odakle zaključujemo da Puasonova raspodela pripada eksponencijalnoj familiji raspodela tako da $T(\mathbf{x}) = \sum_{i=1}^{n} x_i$, $\quad c(\boldsymbol{\lambda}) = \ln \lambda$, $\quad d(\boldsymbol{\lambda}) = \lambda$ i $\quad S(\mathbf{x}) = -\sum_{i=1}^{n} \ln(x_i!)$.

- **Negativna binomna raspodela**: Zakon raspodele negativne binomne slučajne veličine je

$$p(x; p, m) = \binom{x-1}{m-1} p^m (1-p)^{x-m} I\{x \geq m\},$$

  a uzoračka raspodela, kada je m poznato,

$$p(\mathbf{x}; p) = \prod_{i=1}^{n} p(x_i; p, m) = \prod_{i=1}^{n} \binom{x_i - 1}{m-1} p^m (1-p)^{x_i - m} I\{x_i \geq m\}$$

$$= p^{nm} (1-p)^{\sum_{i=1}^{n}(x_i - m)} I\{x_{(1)} \geq m\} \prod_{i=1}^{n} \binom{x_i - 1}{m-1}$$

$$= e^{\sum_{i=1}^{n} x_i \ln(1-p) + \ln I\{x_{(1)} \geq m\} + \sum_{i=1}^{n} \ln \binom{x_i - 1}{m-1} + nm \ln p - nm \ln(1-p)}.$$

  Tada $c(p) = \ln(1-p)$, $T(\mathbf{x}) = \sum_{i=1}^{n} x_i$, $S(\mathbf{x}) = \ln I\{x_{(1)} \geq m\} + \sum_{i=1}^{n} \binom{x_i - 1}{m-1}$ i $d(p) = nm \ln \frac{1-p}{p}$. Dakle, raspodela za X_n je jednoparametarska eksponencijalna familija.

  Kada su oba parametra nepoznata, uzorački prostor zavisi od nepoznatog parametra, samim tim raspodela ne može pripadati eksponencijalnoj familiji raspodela.

□

Teški i laki repovi

Uvedimo

$$x_F = \sup\{t \in \mathbb{R} \mid F(t) < 1\}.$$

Kada je $x_F = +\infty$, raspodela ima nosač koji nije ograničen sa desne strane, tj. desni kraj nosača je $+\infty$.

Neka je F funkcija raspodele za koju važi $F(0) = 0$ i $x_F = +\infty$. Kažemo da funkcija raspodele ima lak rep ako za neko $\lambda > 0$ važi

$$\limsup_{x \to +\infty} \frac{1 - F(x)}{e^{-\lambda x}} < +\infty.$$

Funkcija raspodele F ima težak rep ako za svako $\lambda > 0$ važi

$$\limsup_{x \to +\infty} \frac{1 - F(x)}{e^{-\lambda x}} = +\infty.$$

Napomena. Primetimo da prethodna definicija poredi rep funkcije raspodele F i rep eksponencijalne raspodele $\varepsilon(\lambda)$.

Raspodele sa lakim repovima modeliraju male odštete, dok raspodele teškim repovima modeliraju velike odštete. Sada ćemo pokazati da gama, Puasonova i negativna binomna raspodela imaju lak rep:

- **Gama raspodela** Neka $X \sim \gamma(\alpha, \beta)$, gde je gustina:

  $$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0.$$

  Za velike x, imamo:

  $$\lim_{x \to +\infty} \frac{1 - F(x)}{e^{-\lambda x}} = \begin{cases} 0, & \lambda < \beta, \\ +\infty, & \lambda > \beta. \end{cases}$$

  Dakle, gama raspodela ima **lak rep**.

- **Puasonova raspodela** Neka $X \sim P(\lambda)$. Tada važi:

  $$\mathbb{P}(X > x) = \sum_{k > x} \frac{\lambda^k e^{-\lambda}}{k!}.$$

  Za velike x:

  $$\lim_{x \to +\infty} \frac{\mathbb{P}(X > x)}{e^{-\lambda x}} = 0, \quad \forall \lambda > 0.$$

  Dakle, Puasonova raspodela ima **lak rep**.

- **Negativna binomna raspodela** Neka $X \sim NB(r, p)$. Verovatnoća je:

  $$\mathbb{P}(X = k) = \binom{k + r - 1}{k} p^r (1 - p)^k, \quad k \geq 0.$$

  Za velike k, glavni deo je $(1 - p)^k$, pa:

  $$\lim_{x \to +\infty} \frac{\mathbb{P}(X > x)}{e^{-\lambda x}} = \begin{cases} 0, & \lambda < -\log(1 - p), \\ +\infty, & \lambda > -\log(1 - p). \end{cases}$$

  Dakle, negativna binomna raspodela ima **lak rep**.

1.3 Uopšteni linearni modeli

Većina teorije u prethodnom poglavlju bazirala se na pretpostavci sličnosti (ili homogenosti) između različitih podataka. Ovo je izraženo kroz $i.i.d.$ (nezavisne i identički raspodeljene) pretpostavke o opservacijama. Opšti linearni modeli podrazumevaju centriranost, homoskedastičnost i nekorelisanost slučajnih grešaka modela:

- $\mathbb{E}(\varepsilon) = 0$;
- $\mathrm{D}(\varepsilon) = \sigma^2 I$;
- X i ε su nezavisni slučajni vektori.

Ovaj model je dobro funkcionisao u slučajevima kada predviđamo cenu, težinu ili neku drugu meru. Opšti linearni modeli nisu uvek adekvatan alat zato što u praksi često radimo sa podacima za koje normalna raspodela nije odgovarajuća. Na primer - učestalost nekog događaja ili procenat uspeha. U ovim slučajevima, klasičan linearni model može davati besmislene i netačne rezultate.

1.3.1 Struktura uopštenih linearnih modela

Uopšteni linearni modeli predstavljaju moćan statistički pristup koji se oslanja na tri osnovna koncepta:

- **Linearni prediktor:** η_j predstavlja sveukupan doprinos prediktora za posmatranje j, izračunat kao linearna kombinacija njihovih vrednosti i odgovarajućih koeficijenata.

$$\eta_j = \mathbf{X}_j^T \boldsymbol{\beta} \quad \text{odnosno} \quad \eta_j = \beta_0 + \sum_{i=1}^{p} X_{ji}\beta_i$$

  gde su:

  - η_j — linearni prediktor za j-to posmatranje,
  - $\mathbf{X}_j^T$ — transponovani vektor prediktora (nezavisnih promenljivih) za posmatranje j,
  - $\boldsymbol{\beta}$ — vektor regresionih koeficijenata,
  - β_0 — slobodan član (intercept),
  - X_{ji} — vrednost i-tog prediktora u j-tom posmatranju,
  - β_i — regresioni koeficijent koji odgovara prediktoru X_i,
  - p — broj prediktora

- **Link funkcija:** Jedno od mogućih rešenja problema modelovanja zavisne promenljive čija očekivana vrednost nije slobodna realna vrednost, tj. ne pripada skupu svih realnih brojeva $\mathbb{R}$, jeste da se srednja vrednost ciljne promenljive transformiše u $\mathbb{R}$, a zatim nad transformisanom veličinom primeni linearni model. Ova transformacija, poznata kao ***link funkcija***, omogućava da se ograničeni domen očekivane vrednosti preslika u neograničeni realni prostor. Da bi se transformisana promenljiva mogla opisati linearnim modelom, odnosno $\mu_j = \mathbb{E}[Y_j]$ i za link funkciju g važi

$$g(\mu_j) = \eta_j$$

- **Raspodela ciljne promenljive:** Y_i su nezavisne slučajne promenljive koje pripadaju eksponencijalnoj familiji raspodela sa rasipanjem. Posledica ovakvog pristupa je da se disperzija može predstaviti kao proizvod funkcije srednje vrednosti $V(\mu_j)$ i parametra disperzije C:

$$\mathrm{D}(Y_j) = C \cdot V(\mu_j)$$

1.3.2 Link funkcija

Link funkcija g predstavlja transformaciju koju treba primeniti na funkciju srednje vrednosti zavisne promenljive, da bi se ta transformisana promenjiva mogla opisati linearnim modelom:

- **Aditivni efekti**: Za $g(\mu) = \mu$, dobijamo model:

$$\mu(x) = \mathbb{E}[Y] = \langle \boldsymbol{\beta}, x \rangle = \beta_0 + \sum_{j=1}^{q} \beta_j x_j.$$

- **Multiplikativni efekti**: Za $g(\mu) = \log(\mu)$, model ima oblik:

$$\mu(x) = \mathbb{E}[Y] = \exp(\langle \boldsymbol{\beta}, x \rangle) = e^{\beta_0} \prod_{j=1}^{q} e^{\beta_j x_j}.$$

Link funkcija g mora biti monotona i diferencijabilna.
Primer najčešćih link funkcija:

Link funkcija $g(\mu)$	**Opis**
μ	Identična
$\ln(\mu)$	Logaritamska
μ^2	Stepenovana
$\sqrt{\mu}$	Kvadratni koren
$\ln\left(\frac{\mu}{1-\mu}\right)$	Logit funkcija

Log-link je čest izbor u osiguranju jer omogućava jednostavnu interpretaciju promena cene u procentima osnovne premije.

2 ULM u aktuarstvu

Uopšteni linearni modeli predstavljaju prirodno proširenje opštih (klasičnih) linearnih modela i omogućavaju modelovanje zavisnih promenljivih koje ne moraju biti normalno raspodeljene (u našem slučaju, pripadaju eksponencijalnoj familiji raspodela). Oni se dosta često pojavljuju u primeni neživotnog osiguranja, kao što su na primer broj šteta, iznosi šteta, verovatnoća zahteva itd.

2.1 Izbor uopštenog linearnog modela

Na početku je potrebno izabrati člana eksponencijalne familije raspodela koji odgovara problemu modelovanja.

Kao prvi korak, treba razumeti svojstva podataka Y pre izbora modela. Potrebni su nam podaci koji imaju lake repove. Ukoliko naši podaci imaju teške repove prvo ćemo ih transformisati ($log(Y)$) pa tek onda ćemo ih modelovati članom EDF-a.
Ako se izabere Gausova raspodela za $log(Y)$, onda će Y biti log-normalno distribuiran. Međutim, ako se izabere eksponencijalna raspodela za $log(Y)$, onda će Y biti Pareto distribuiran.

Kao drugi korak, treba izabrati funkcije veze (Link Function). Sa statističke tačke gledišta, trebalo bi izabrati kanonsku funkciju veze $g = h$, kako bi se srednja vrednost μ modela povezala sa linearnim prediktorom ν. Ovaj izbor obezbeđuje brojne povoljne matematičke osobine. U određenim slučajevima bolje je koristiti druge funkcije, npr. identitetsku funkciju veze koristimo kada imamo model sa aditivnim efektima, a logaritamsku funkciju veze kada imamo multiplikativni model.

Drugi zahtev je da rezultujući kanonski parametar $\boldsymbol{\theta} = (h \circ g^{-1})(\eta)$ bude unutar efektivnog domena Θ.

Izbor i inženjering atributa (Feature Engineering)
Pretpostavimo da smo izabrali člana EFR-a i funkciju veze g. Ovo nam daje odnos između srednje vrednosti μ i linearnog prediktora η.

$$\mu(x) = \mathbb{E}_\theta[Y] = g^{-1}(\eta(x)) = g^{-1}(\langle \boldsymbol{\beta},\ x \rangle)$$

Dakle, atributi $x \in X \subset \mathbb{R}^{q+1}$ treba da budu u odgovarajućoj funkcionalnoj formi kako bi mogli da pravilno opišu sistematski efekat kroz funkciju.
Razlikujemo sledeće tipove karakteristika:

- **Neprekidne realne komponente**, primeri: starost osiguranika, težina vozila, indeks telesne mase itd.
- **Ordinalne kategoričke komponente**, primeri: ocena dobar-srednji-loš, kategorije poput A-B-C-D-E.
- **Nominalne kategoričke komponente**, primeri: brendovi vozila, zanimanja osiguranika itd.
- **Binarne komponente**, specijalne kategoričke promenljive koje imaju samo dva nivoa, npr. žensko-muško, otvoreno-zatvoreno.

Sve ove komponente treba transformisati u odgovarajući oblik da bi se koristile u linearnom prediktoru $\eta(x) = \langle \boldsymbol{\beta},\ x \rangle$. Ovo zahteva razmatranje sledećih tačaka:

- transformacija kontinualnih komponenti kako bi opisale sistematske efekte u linearnoj formi,
- transformacija kategorijalnih komponenti u realne komponente,
- interakcija komponenti van aditivne strukture u linearnom prediktoru, i
- dizajn matrice $\boldsymbol{X}$ treba da ima pun rang $q + 1 \leq n$.

2.2 Feature Engineering

Kodiranje pomoću pseudopromenljivih

Kategoričke promenljive treba ugraditi u Euklidski prostor. Mora biti izvedeno tako da rezultujuća dizajn matrica $\boldsymbol{X}$ ima pun rang $q+1 \leq n$. Postoji više različitih načina da se ovo uradi, a specifičan izbor zavisi od svrhe modelovanja. Najpopularniji način je kodiranje pomoću pseudopromenljivih. Izbor načina kodiranja ne utiče na prediktivni model (ako radimo sa dizajn matricom punog ranga), ali može uticati na izbor parametara, redukciju parametara i interpretaciju modela.

Pretpostavimo da je $\tilde{x}_j$ kategorička promenljiva koja ima $\boldsymbol{K}$ različitih nivoa$\{a_1, a_2, ..., a_{\boldsymbol{K}}\}$. Kodiranjem pseudopromenljivama, jedan nivo, recimo $a_{\boldsymbol{K}}$, se proglašava referentnim nivoom, a svi ostali nivoi se opisuju u odnosu na taj referentni nivo.

Binarne komponente karakteristika

Binarne komponente karakteristika ne zahtevaju poseban tretman u odnosu na kategoričke. One su Bernulijeve promenljive koje mogu biti kodirane kao 0 ili 1. U kodiranju sa pseudopromenljivima stavimo da nam je $\boldsymbol{K} = 2$.

Neprekidne komponente karakteristika

One ne zahtevaju prethodnu obradu jer su već u pravom formatu za skalarni proizvod. Ipak, u mnogim slučajevima, i one moraju da prođu kroz Feature Engineering jer samo u retkim slučajevima one direktno odgovaraju funkcionalnoj formi.

Razmotrimo vozače koji imaju različito iskustvo u vožnji i različite veštine u vožnji. Da bismo objasnili iskustvo i veštine, obično izaberemo starost vozača kao promenljivu. Modelujući frekvenciju zahteva kao funkciju starosti vozača, često primećujemo funkciju koja nije monotona u odnosu na starost vozača. Pošto funkcija veze g mora biti strogo monotona, ovaj regresivni problem ne može se direktno modelovati uz uključivanje starosti vozača kao elementa u formulu.

U ovim situacijama, neprekidne promenljive se obično diskretizuju u kategoričke klase. U primeru sa starošću vozača, pravimo starosne grupe. Ove starosne grupe se zatim tretiraju kao kategoričke promenljive, koristeći kodiranje pomoću pseudopromenljivih.

Nedostak ovog pristupa je što susedne starosne grupe neće biti prepoznate od strane regresione funkcije jer, po definiciji, kodiranje pseudopromenljivim podrazumeva da kategorički nivoi nemaju nikakvu topologiju.

2.3 Modeliranje neprekidnih promenljivih

2.3.1 Gama regresija

Gama slučajna promenljiva je najčešće najpogodnija za fitovanje promenljivih kao što je iznos zahteva za odštetu ili godišnji prihod osiguranika.
Neka $Y \sim G(\mu, \nu)$, njena funkcija verovatnoće je

$$f(y) = \frac{y^{\nu-1}}{\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^{\nu} e^{-y\nu/\mu}, \quad y > 0$$

i važi da je $E(Y) = \mu, \quad D(Y) = \frac{\mu^2}{\nu}$.
Male vrednosti parametra ν utiču na to da je raspodela dosta iskošena udesno, tj. da ima dugačak "rep"udesno.
Uopšten linearni model sa gama raspodelom zavisne promenljive dat je sa

$$Y \sim G(\mu, \nu),\ g(\mu) = x'\beta,$$

gde se za link funkciju najčešće bira logaritamska.

2.3.2 Inverzna Gausova regresija

Inverzna Gausova raspodela spada u neprekidne raspodele i data je sa funkcijom gustine

$$f(y;\mu,\lambda=1)=\sqrt{\frac{1}{2\pi y^3}}\exp\left(-\frac{(y-\mu)^2}{2\mu^2 y}\right),\quad y>0$$

Sa osobinama: $E(Y)=\mu,\quad \mathrm{D}(Y)=\mu^3$.

Inverzna Gausova raspodela je više iskošena nego gama raspodela i ima oštriji rep udesno. Zato se koristi u situacijama ekstremne kosine.

Za modeliranje neprekidnih varijabli u aktuarstvu kao što je iznos zahteva za odštetu, veličina zahteva koju osiguravajuća kompanija treba da plati uglavnom se koriste Inverzna Gausova raspodela, gama raspodela, Veibulova, Pareto, itd.

Uopšteno linearno modeliranje sa Inverznom Gausovom raspodelom je

$$Y\sim IG(\mu,\lambda),\ g(\mu)=x'\beta,$$

gde se za funkciju g najčešće bira logaritamska funkcija.

2.4 Modeliranje diskretnih promenljivih

2.4.1 Puasonova regresija

Puasonova raspodela je uobičajena raspodela za modeliranje celobrojnih podataka. Neka je Y slučajna promenljiva koja broji koliko puta se realizovao događaj od interesa, npr. broj zahteva za odštetu u okviru jedne grupe polisa osiguranja sa trajanjem ω_i i neka je μ_i očekivana vrednost ako je $\omega_i=1$. Njena raspodela verovatnoća je data sa

$$f(y;\mu)=\frac{(\omega\mu)^y e^{-\omega\mu}}{y!},\quad y=0,1,2,\ldots$$

gde je μ prosečan broj realizovanih događaja. Pritom je $E(Y)=D(Y)=\omega\mu$.

Parametar μ se obično predstavlja kao stopa. Na primer, kod sudara motornih vozila parametar μ može predstavljati prosečan broj sudara na 1000 stanovnika, ili na 1000 motornih vozila ili prosečan broj sudara na 1000km pređenog puta. Takođe tu treba uključiti i vremensku komponentu tj. vremenski period za koji se ta stopa izračunava. Stopa sudara kod motornih vozila se obično računa na nivou jedne godine.

Neka je $N(t)$ broj zahteva za odštetu za individualnu polisu osiguranja, dok traje vremenski period $[0,t]$ tako da je $N(t)=0$. Taj stohastički proces se naziva proces zahteva za odštetu, i on je Puasonov proces. Na osnovu toga možemo pretpostaviti da broj zahteva u okviru individualne polise ima Puasonovu raspodelu.

Nas interesuje učestalost zahteva za odštetu $Z_i=\frac{Y_i}{\omega_i}$ za koju se kaže da prati relativnu Puasonovu raspodelu. Neka su Z_1 i Z_2 frekvencije zateva za dve različite grupe polisa koje imaju trajanje ω_1 i ω_2 i obe prate relativnu Puasonovu raspodelu sa očekivanjem μ.

Ukoliko spojimo te grupe polisa polisa dobićemo novu promenljivu za frekvenciju zahteva, Z koja predstavlja težinsku aritmetičku sredinu

$$Z=\frac{\omega_1 Z_1+\omega_2 Z_2}{\omega_1+\omega_2}$$

Uopšteni linearni model je dat sa

$$E(Y_i)=\mu_i=n_i e^{x_i'\beta},\quad Y_i\sim P(\mu_i)$$

$$\ln(\mu_i) = \ln(n_i) + x_i'\beta$$

Član $\ln(n_i)$ se naziva offset.

Za testiranje hipoteza o parametrima β_j koristi se Valdov test, skor test ili test količnika verodostojnosti.

Za interval poverenja se koristi sledeća test statistika

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim N(0,1)$$

2.4.2 Overdispersion

Slučajne varijacije između kupaca polisa osiguranja, osiguranih objekata i efekat nezavisnih promenljivih koje nisu uključene u model dovodi do pojma overdispersion tj. prevelika disperzija. Disperzija opservacija u okviru grupe polisa je veća nego disperzija za pretpostavljenu Puasonovu raspodelu, gde se očekuje da su srednja vrednost i disperzija jednake. Do overdisperzije dolazi zato što su srednja vrednost i disperzija u ULM-u funkcionalno povezane preko istog parametra. Ova pojava može biti rezultat mnogih faktora, propuštanje prediktora, nehomogenost u populaciji, zavisnost među posmatranjima ili jednostavno nesavršenosti modela u obuhvatanju složenosti podataka.

Da bismo uočili overdisperziju, najčešće, koristimo *dispersiontest* (test ugrađen u R-u) ili upoređujemo odnos devijanse modela i broja stepeni slobode. Ukoliko je on značajno veči od 1 možemo da zaključimo da je došlo do overdisperzije.

U oblasti osiguranja, overdisperzija je posebno česta kod modelovanja broja zahteva za odštetu. Prava učestalost zahteva može biti značajno više varijabilna od Puasonove pretpostavke zbog razlika u ponašanju klijenata, rizicima, sezonama, vrstama polisa itd. Korišćenjem ULM modela bez uvažavanja overdisperzije može se doneti pogrešna odluka o cenama premije.

2.4.3 Negativna binomna regresija

Dakle, mogli smo da primetimo da za korišćenje Puasonove raspodele moramo da imamo ispunjen uslov da je srednja vrednost jednaka disperziji. Rešenje za čestu overdisperziju ($D(Y) > E(Y)$) nalazimo u korišćenju negativne binomne raspodele jer nam je u njoj dozvoljeno da disperzija bude veća od srednje vrednosti. Koristimo je za modeliranja broja zahteva za odštetu.

Negativni binomni regresioni model sa link funkcijom logaritma je

$$X \sim NB(\mu, \kappa), \quad \ln(\mu) = \ln(n) + \beta_1 + \beta_2 \ln(z)$$

x je zavisna promenljiva koja predstavlja broj zahteva za odštetu, z je nezavisna promenljiva, n je veličina populacije i $ln(n)$ predstavlja Offset termin.

2.5 Zero-Inflated modeli

U statistici se najčešće koristi Puasonova regresija kao alat za analizu numeričkih podataka. Međutim, videli smo da nije pogodna u svim slučajevima. Prvo, zbog overdisperzije, a drugi i veći problem sa Puasonovom regresijom može biti taj što je broj posmatranih nula veći od onog što model predviđa.

Zero-inflated Puasonov model ili **Zero-inflated model negativne binomne raspodele** nudi rešenje u takvim slučajevima. Ovi modeli su mešavina modela u kojima je celokupna raspodela ishoda predstavljena kroz dve odvojene komponente, prvi deo modelira verovatnoću viška nula, a drugi deo obuhvata preostale nule i pozitivne brojeve.

2.5.1 ZIP modeli - Zero-Inflated Puasonovi modeli

Razmotrimo uzorak od n nezavisnih posmatranih vrednosti Y_i. U ZIP regresiji, vrednosti Y_i su jednake nuli sa verovatnoćom p_i, dok sa verovatnoćom $1 - p_i$ prate Puasonovu raspodelu sa srednjom vrednošću λ_i. Može se zaključiti da

$$\Pr(Y_i = 0) = p_i + (1 - p_i)\exp(-\mu_i),$$

$$\Pr(Y_i = k) = (1 - p_i)\exp(-\mu_i)\frac{\mu_i^k}{k!}, \quad k = 1, 2, \ldots$$

Potrebno je naglasiti da posmatrane nule potiču i iz nultne komponente raspodele i iz Puasonove raspodele. Nultna komponenta raspodele je, dakle, povezana sa modelovanjem "viška"ili "inflacionih"nula, koje se pojavljuju pored onih nula koje bi se očekivale prema pretpostavljenoj raspodeli.

Da bi se procenio uticaj kovarijata na raspodelu brojeva u ZIP modelu, verovatnoća p_i i srednja vrednost μ_i mogu se eksplicitno izraziti kao funkcije kovarijata. Najprirodniji izbor za modelovanje verovatnoće viška nula jeste primena logističke regresije

$$\text{logit}(p_i) = \mathbf{x}_i^\top \boldsymbol{\beta},$$

gde $\mathbf{x}_i$ predstavlja vektor kovarijata, a β predstavlja vektor parametra (regresionih koeficijenata).

Procene za β u ovim modelima se mogu dobiti metodom maksimalne verodostojnosti.

2.5.2 ZINB modeli - Zero-Inflated Negativna binomna

Brojčani podaci često pokazuju veću disperziju nego što to predviđa srednja vrednost Puasonove raspodele — čak i nakon što se uzme u obzir višak nula. Jedan od načina da se modeluju takvi brojčani podaci jeste da se pretpostavi da Y_i prati raspodelu negativne binomne raspodele (ZINB).

Disperzija slučajne promenljive je $\frac{\lambda+\lambda^2}{\theta}$. Jasno je da negativna binomna raspodela prelazi u Puasonovu raspodelu kada θ teži ka beskonačnosti (tj. kada nema overdisperzije).

Srednja vrednost i disperzija nultom inflacijom negativne binomne raspodele su $E(Y) = (1 - p)\lambda$ i $D(Y) = (1-p)\lambda(1 + \lambda + \frac{\lambda}{\theta})$. Ako su i $\frac{1}{\theta}$ i p približno jednaki nuli, tada se ZINB raspodela takodje svodi na Puasonovu raspodelu.

$$\Pr(Y_i = 0) = p_i + (1 - p_i)\left(\frac{\theta}{\mu_i + \theta}\right)^\theta$$

$$\Pr(Y_i = k) = (1 - p_i) \cdot \frac{\Gamma(k + \theta)}{\Gamma(\theta) \cdot k!} \times \frac{\mu_i^{\urcorner}\theta^\theta}{(\mu_i + \theta)^{\urcorner+\theta}}, \quad k = 1, 2, \ldots$$

gde je μ_i srednja vrednost, θ parametar oblika i Γ je gama funkcija.

Kad je $\theta = 1$ negativna binomna raspodela se pretvara u geometrijsku raspodelu.

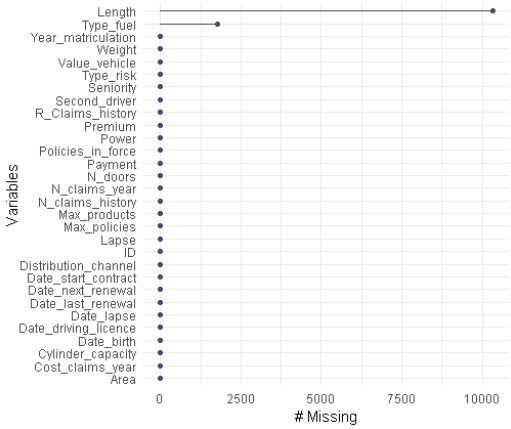
3 Primena uopštenih linearnih modela u aktuarstvu

Motivacija za korišćenje uopštenih linearnih modela koji koriste Puasnovu familiju raspodela je bila logičan sled vodeći se njenim prethodno pomenutim osobinama. Pripadnost eksponencijalnoj familiji raspodela i posedovanje lakog repa je čini teorijski pogodnim izborom za modelovanje diskretne velicine.

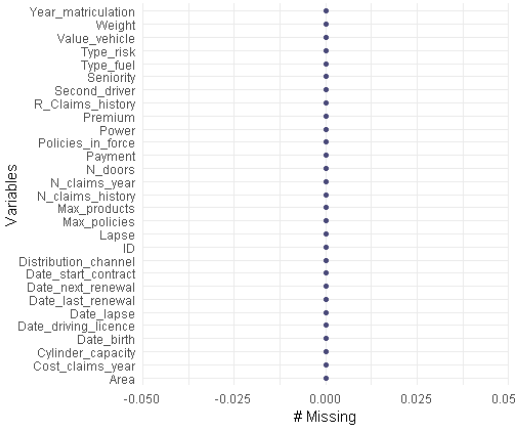
Za rad smo koristili bazu koja ima 105 555 opservacija, sto je cini poprilicno velikom bazom za rad. Medjutim u njoj nailazimo na problem nedostajucih vrednosti. Ukoliko bismo uklonili sve opservacije koje imaju nedostajuće vrednosti, izgubili bismo znacajan broj podataka. Resenje tog problema smo našli u analizi promenljivih sadrže najviše *NA* vrednosti i izbacivanjem istih.

```
data <- read.csv("data.csv")
gg_miss_var(data)
data <- data[, -29]
newdata <- na.omit(data)
gg_miss_var(newdata)
```

Vidimo da je promenljiva sa najvećim brojem *NA* vrednosti promenljiva *Length*, pa je ukljanjamo kao i sve ostale opservacije koje sadrže *NA* vrednost:



Slika 1: Početna baza



Slika 2: Baza nakon uklanjanja *NA* vrednosti

Nakon toga, pretvaramo nenumeričke prediktore u numeričke. To je u ovom slučaju samo kolona *Type fuel* koja nosi informaciju o tome da li osigurano vozilo ide na benzin **(P)** ili dizel **(D)**.

Iz promenljive *Date birth* i tekuće godine iz koje je ova baza, a to je 2018. godina, računamo starost lica koje je osiguralo dato vozilo, i sličnom logikom dužinu posedovanja vozačke dozvole iz promenljive *Date driving licence*, kao i starost vozila iz *Year matriculation*.

Nakon toga, odlučujemo se za izbacivanje prediktora koji su interni osiguravajućoj kući, i koji nose informacije o "budućnosti", a to su *Date start contract*, *Date last renewal*, *Date next renewal*, *Distribution channel*, *Seniority*, *Policies in force*, *Max policies*, *Max products*, *Lapse*, *Date lapse*, *Payment*, *Premium*, kao i *R claims history*.

Prva kolona baze podataka je *ID* osiguranika, te vidimo da postoji više različitih ugovora koje ima isti osiguranik za više godina tokom kojih je bio sa datom osiguravajućom kućom. Analiza u kojoj smo uzimali u obzir takve informacije kako bismo napravili precizniji model pokazala se izuzetno kompleksnom i nepraktičnom za ovu bazu podataka. Zbog toga smo odlučili da posmatramo samo prvu instancu svakog pojedinca,

odnosno podatke iz prve kalendarske godine, kako bismo imali najsvežiji i najravnopravniji podatak za svakog osiguranika.

3.1 Predviđanje broja odšteta

3.1.1 Puasonov model

Prvo ćemo se baviti predvidjanjem promenljive *N claims year* koja označava broj odšteta koje je osiguranik tražio u datoj godini. To je bitna informacija za osiguravajuću kuću kako bi mogla tačnije da proceni premiju za novog osiguranika.

Treniramo uopšteni linearni model sa Puasonovom raspodelom:

```
model <- glm(train_data$N_claims_year ~ ., family = poisson(link = "log"), data
    = train_data)
summary(model)
```

Možemo primetiti da postoje prediktori koji su se pokazali možda manje značajnim za trenutni model što ćemo kasnije proveriti.

```
Call:
glm(formula = train_data$N_claims_year ~ ., family = poisson(link = "log"),
    data = train_data)

Coefficients:
                       Estimate Std. Error z value Pr(>|z|)
(Intercept)          -0.5535681  0.0105622 -52.410  < 2e-16 ***
Distribution_channel1  0.0151298  0.0118117   1.281 0.200225
Type_risk            -0.0854162  0.0076722 -11.133  < 2e-16 ***
Area1                 0.2152545  0.0127264  16.914  < 2e-16 ***
Second_driver1        0.2692214  0.0164068  16.409  < 2e-16 ***
Power                 0.0344451  0.0097746   3.524 0.000425 ***
Cylinder_capacity     0.1430722  0.0133316  10.732  < 2e-16 ***
Value_vehicle        -0.0007571  0.0101643  -0.074 0.940620
N_doors               0.1029419  0.0078839  13.057  < 2e-16 ***
Type_fuel1           -0.1742972  0.0147508 -11.816  < 2e-16 ***
Weight                0.0361923  0.0114516   3.160 0.001575 **
Vehicle_age           0.0542637  0.0071621   7.577 3.55e-14 ***
years                 0.0304723  0.0119307   2.554 0.010646 *
Duration_of_dl       -0.1029012  0.0119008  -8.647  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 88161  on 47380  degrees of freedom
Residual deviance: 85637  on 47367  degrees of freedom
AIC: 119668

Number of Fisher Scoring iterations: 7
```

Slika 3: Summary: Puasonov model

Odlučujemo se da odbacimo te prediktore, i da proverimo ***anova*** testom da li je to bilo opravdano, što se ispostavlja da jeste. Nakon toga proveravamo ***MSE*** i ***MAE*** našeg modela.
Sledeća bitna stvar jeste proveravanje raspršenja, jer Puasonova raspodela ne rukuje dobro sa raspršenjem.

```
model_3<-glm(train_data$N_claims_year ~ .-Value_vehicle - Distribution_channel,
    family = poisson(link="log"), data = train_data)
summary(model_3)#AIC: 119666
```

```r
pred_valid3 <- predict(model_3, newdata = valid_data, type = "response")

MSE(y_valid,pred_valid3)#1.90954151356755
MAE(y_valid,pred_valid3)#0.879517413827106

anova(model,model_3,  test = "Chisq")

dispersion <- sum(residuals(model_3, type = "pearson")^2) / df.residual(model)
dispersion
#postoji rasejanje

dispersiontest(model)
```

Pokazuje se da je disperzija veća od 1 što nas dovodi do zaključka da postoji raspršenje. To je takodje potvrdjeno funkcijom ***dispersiontest***.

```
        Overdispersion test

data:  model
z = 35.052, p-value < 2.2e-16
alternative hypothesis: true dispersion is greater than 1
sample estimates:
dispersion
  2.846141
```

Slika 4: Overdispersion test

```
Call:
glm(formula = train_data$N_claims_year ~ . - Value_vehicle -
    Distribution_channel, family = poisson(link = "log"), data = train_data)

Coefficients:
                  Estimate Std. Error z value Pr(>|z|)
(Intercept)      -0.546725   0.009100 -60.082  < 2e-16 ***
Type_risk        -0.085803   0.007665 -11.194  < 2e-16 ***
Area1             0.217441   0.012611  17.242  < 2e-16 ***
Second_driver1    0.270330   0.016383  16.501  < 2e-16 ***
Power             0.034077   0.007906   4.310 1.63e-05 ***
Cylinder_capacity  0.143180   0.013019  10.998  < 2e-16 ***
N_doors           0.103211   0.007796  13.239  < 2e-16 ***
Type_fuel1       -0.175075   0.014737 -11.880  < 2e-16 ***
Weight            0.035758   0.011207   3.191  0.00142 **
Vehicle_age       0.054099   0.007052   7.671 1.70e-14 ***
years             0.030919   0.011924   2.593  0.00951 **
Duration_of_dl   -0.103635   0.011884  -8.720  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 88161  on 47380  degrees of freedom
Residual deviance: 85639  on 47369  degrees of freedom
AIC: 119666

Number of Fisher Scoring iterations: 7
```

Slika 5: Summary: model 3

3.1.2 Negativna binomna

S obzirom na to da negativna binomna raspodela bolje kontroliše overdispersion (raspršenje), istrenirajmo uopšteni linearni model sa negativnom binomnom raspodelom:

```r
nb_model <- glm.nb(N_claims_year ~ ., data = train_data)
summary(nb_model)#AIC: 96549
```

Ponavljamo postupak od malopre, izbacujemo manje značajne prediktore, i proveravamo disperziju:

```
Call:
glm.nb(formula = N_claims_year ~ ., data = train_data, init.theta = 0.327078643,
    link = log)

Coefficients:
                     Estimate Std. Error z value Pr(>|z|)
(Intercept)          -0.56746    0.01791 -31.686  < 2e-16 ***
Distribution_channel1  0.01632    0.02036   0.801 0.422992
Type_risk            -0.05532    0.01354  -4.086 4.38e-05 ***
Area1                 0.21624    0.02251   9.607  < 2e-16 ***
Second_driver1        0.27784    0.02960   9.388  < 2e-16 ***
Power                 0.03250    0.01728   1.880 0.060048 .
Cylinder_capacity     0.16427    0.02406   6.828 8.60e-12 ***
Value_vehicle        -0.02025    0.01893  -1.070 0.284770
N_doors               0.08655    0.01356   6.380 1.77e-10 ***
Type_fuel1           -0.15495    0.02495  -6.211 5.26e-10 ***
Weight                0.07897    0.02164   3.649 0.000264 ***
Vehicle_age           0.04711    0.01204   3.912 9.17e-05 ***
years                 0.03891    0.02092   1.860 0.062897 .
Duration_of_dl       -0.11345    0.02090  -5.428 5.71e-08 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for Negative Binomial(0.3271) family taken to be 1)

    Null deviance: 33310  on 47380  degrees of freedom
Residual deviance: 32347  on 47367  degrees of freedom
AIC: 96549

Number of Fisher Scoring iterations: 1
```

Slika 6: Summary: nb modela

```r
nb_model_2 <- glm.nb(N_claims_year ~ .-Value_vehicle -Distribution_channel, data
    = train_data)
summary(nb_model_2)#AIC:96547

dispersion_nb_2 <- sum(residuals(nb_model_2, type = "pearson")^2) / df.residual(
   nb_model_2)
dispersion_nb_2# 0.993099
anova(nb_model, nb_model_2, test ="Chisq")
```

Vidimo da je izbacivanje prediktora bilo opravdano. Ovaj put nemamo problem sa overdisperzijom zato što je disperzija manja od 1.

```
Likelihood ratio tests of Negative Binomial Models

Response: N_claims_year

Model
1 (Distribution_channel + Type_risk + Area + Second_driver + Power + Cylinder_capacity + Value_v
ehicle + N_doors + Type_fuel + Weight + Vehicle_age + years + Duration_of_dl) - Value_vehicle -
Distribution_channel
2                                  Distribution_channel + Type_risk + Area + Second_driv
er + Power + Cylinder_capacity + Value_vehicle + N_doors + Type_fuel + Weight + Vehicle_age + ye
ars + Duration_of_dl
      theta Resid. df    2 x log-lik.   Test    df LR stat.   Pr(Chi)
1 0.3270829     47369       -96520.99
2 0.3270786     47367       -96519.25 1 vs 2     2 1.747314 0.4174222
```

Slika 7: Prikaz *anova* testa

3.1.3 Uvođenje interakcija

Možemo probati da uvedemo neke interakcije između prediktora kako bi smo probali da poboljšamo model:

```
numeric <- c("Power", "Cylinder_capacity", "Value_vehicle",
                "N_doors", "Weight","years", "Duration_of_dl", "Vehicle_age ")

formula <- as.formula(paste("N_claims_year ~ Type_fuel * (", paste(numeric,
    collapse = " + "), ") + Type_risk * (", paste(numeric, collapse = " + "), ")
    + Area * (", paste(numeric, collapse = " + "), ")+ Second_driver * (", paste
    (numeric, collapse = " + "), ") + Distribution_channel * (", paste(numeric,
    collapse = " + "), ")"))

model3 <- glm(formula, data = train_data, family = poisson)

# Pregled rezultata modela
summary(model3)
#AIC: 118395
```

Dobili smo relativno iste vrednosti metrika za ovaj model, ali smo izgubili na interpretabilnosti modela.

3.1.4 Zero-Inflated modeli

Kako su zero-inflated modeli sposobni da rade sa podacima koji su *zero heavy*, poput naših, jer velika većina osiguranika nije uopšte tražila odštetu u datoj godini. To nam može dati vetar u ledja da probamo ovakav pristup za naše podatke. Originalno ova ideja je proistekla iz problema sa konvergencijom modela sa kojima smo se susretali kada smo pokušavali da radimo sa više internih podataka iz osiguravajuće kuće.

```
zinb_model_2 <- zeroinfl(
  N_claims_year ~ Area + Second_driver + Power + Cylinder_capacity + Value_
      vehicle +
    N_doors + Type_fuel + Weight + Vehicle_age + Duration_of_dl
  | Type_risk + Area + Second_driver + Power + Value_vehicle + N_doors +
    Weight + Vehicle_age + Duration_of_dl,
  data = train_data,
  dist = "negbin")
```

Treniramo zero-inflated modele sa Puasonovom i negativnom binomnom raspodelom, radi uporedjivanja.

```
zip_model_2 <- zeroinfl(
  N_claims_year ~ Distribution_channel + Type_risk + Area + Second_driver +
    Power + Cylinder_capacity + Value_vehicle + N_doors + Type_fuel +
    Weight + Vehicle_age
  | Distribution_channel + Area + Second_driver + Power + Cylinder_capacity +
    N_doors + Type_fuel + Duration_of_dl,
  data = train_data,
  dist = "poisson")
```

Iako smo očekivali bolju interpretaciju, dati modeli daju efektivno iste rezultate.

3.2 Predviđanje vrednosti odštete

Za osiguravajuće kuće veoma bitna informacija jeste očekivana vrednost odštete koja će morati da bude isplaćena osiguraniku, ako dodje do odgovarajuće štete. U našim podacima nalaze se dve kolone koje koristimo da dobijemo prosečnu odštetu po polisi. To je gore pomenuti *N claims year* i *Cost claims year*, kolona koja sadrži informaciju o ukupnoj količini novca koja je isplaćena za datu polisu u jednoj godini. Deljenjem te dve kolone dobijamo prosečnu štetu koju je osiguranje pokrilo.

Sličnim postupkom kao za modele koji predvidjaju broj odšteta tako i kod modela za cenu odštete biramo samo one prediktore koji su važni za predvidjanje ciljne promenljive. *Anova* testiranjem dobijamo da smo učinili pravu stvar. Probaćemo dva uopštena linearna modela: sa Inverznom Gausovom raspodelom, i sa Gama raspodelom. Razlog za to je sposobnost za rad sa neprekidnim podacima ova dve raspodele.

```
newdata_cost <- first_year_data[,c(16,17,20,21,22,24,25,26,27,28,29,32,33,34)]
View(newdata_cost)
is.numeric(newdata_cost)

data_scaled_cost<-newdata_cost[-which(newdata_cost$Cost_claims_year==0),]

numeric_cols <- sapply(data_scaled_cost, is.numeric)
data_scaled_cost[numeric_cols] <- scale(data_scaled_cost[numeric_cols])
```

Nakon redukcije atributa u bazi i skaliranja pravimo modele.

```
model_gamma <- glm(avg_claim_cost ~ ., data = train_data,family = Gamma(link = "
    log"),control = glm.control(maxit = 100, epsilon = 1e-8))
```

```
model_invgauss <- glm(avg_claim_cost ~ ., data = train_data, family = inverse.
    gaussian(link = "log"))
```

```
model_invgauss_simpler <- glm(avg_claim_cost ~ Vehicle_age + Duration_of_dl,data
     = train_data, family = inverse.gaussian(link = "log"))
summary(model_invgauss_simpler)

get_mae_avg_cost(model_invgauss_simpler, valid_data)
get_rmse_avg_cost(model_invgauss_simpler, valid_data)
# MAE 464.5212, RMSE 969.5812, isto

anova(model_invgauss_simpler, model_invgauss)
```

```
Analysis of Deviance Table

Model 1: avg_claim_cost ~ Vehicle_age + Duration_of_dl
Model 2: avg_claim_cost ~ Type_risk + Area + Second_driver + Power + Cylinder_capacity +
    Value_vehicle + N_doors + Type_fuel + Weight + Vehicle_age +
    years + Duration_of_dl
  Resid. Df Resid. Dev Df Deviance     F Pr(>F)
1     12059     116.27
2     12049     115.91 10  0.36303 1.476 0.1412
```

Slika 8: Prikaz *anova* testa

```
rf_model <- randomForest(avg_claim_cost ~ ., data = train_data,  ntree  = 500 )
```

Nakon treniranja ovih modela uvideli smo da svi modeli osim *random forest* modela imaju prilično slične rezultate, dok se *random forest* pokazao kao najgori. Analiziranjem summary-ja svakog od ovih modela odlučili smo se za jednostavniji model inverzne Gausove raspodele.

3.3 Odabir odgovarajućeg modela

3.3.1 Predviđanje broja odšteta

Nakon treniranja većeg broja modela i uspoređivanja vrednosti metrika na validacionom testu, odlučili smo se da izaberemo dva finalna modela sa redukovanim brojem prediktora: Puasonov model i model negativne binomne regresije. Gledajući vrednosti metrika razlika između ova dva modela je minimalna, ali model negativne binomne regresije krasi činjenica da pojava rasejanja ne postoji.

```
model_poisson<-glm(N_claims_year~.-Value_vehicle - Distribution_channel, data=
    full_data, family = "poisson"(link = log))
summary(model_poisson)

dispersion <- sum(residuals(model_poisson, type = "pearson")^2) / df.residual(
    model_poisson)
dispersion #2.842326 postoji pojava rasejanja

prediction_poisson<- predict(model_poisson, newdata = test_data, type = "
    response")

MSE(y_test, prediction_poisson)#1.61677586712868
MAE(y_test, prediction_poisson)#0.854630826531937

dispersiontest(model_poisson)
plot(rstandard(model_poisson)~fitted(model_poisson))
```

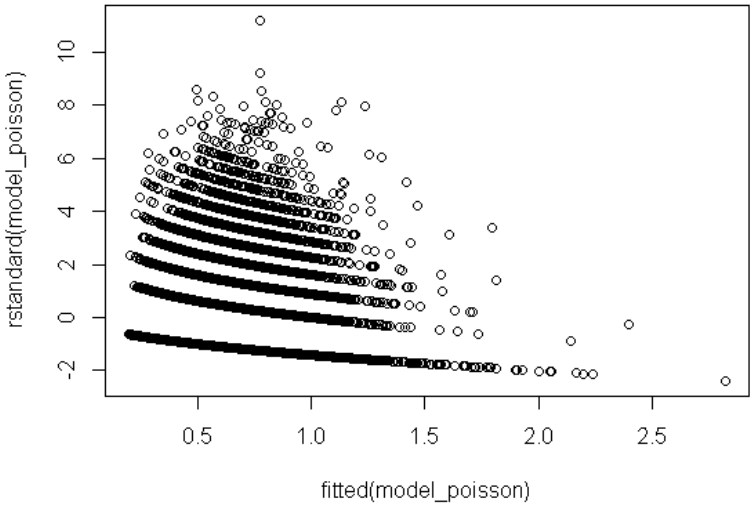
```
        Overdispersion test

data:  model_poisson
z = 36.146, p-value < 2.2e-16
alternative hypothesis: true dispersion is greater than 1
sample estimates:
dispersion
  2.846741
```

Slika 9: Overdispersion test

Kao što vidimo, *overdispersion* test potvrđuje da postoji rasejanost u ovom modelu, što ga čini lošijim od modela negativne binomne.

Reziduali koji se mogu videti na plotu su koncentrisani u linijama koje su nastale kao posledica velikog broja kategoričkih prediktora u bazi podataka na kojoj vršimo istraživanje. Takođe, možemo primetiti da disperzija reziduala raste sa porastom prediktovanih vrednosti modela. Možemo zaključiti da ova raspodela nije dovoljno dobra jer ona pretpostavlja da je disperzija jednaka matematičkom očekivanju.



Slika 10: Reziduali puasonove regresije

Zbog toga se okrećemo ka modelu koji koristi negativnu binomnu raspodelu jer on uključuje parametar koji kontroliše disperziju. U narednom delu koda, predstavljamo treniranje izrabranog modela.

```
model_negbin<-glm.nb(N_claims_year~.-Value_vehicle -Distribution_channel, data=
    full_data)

summary(model_negbin)#101852

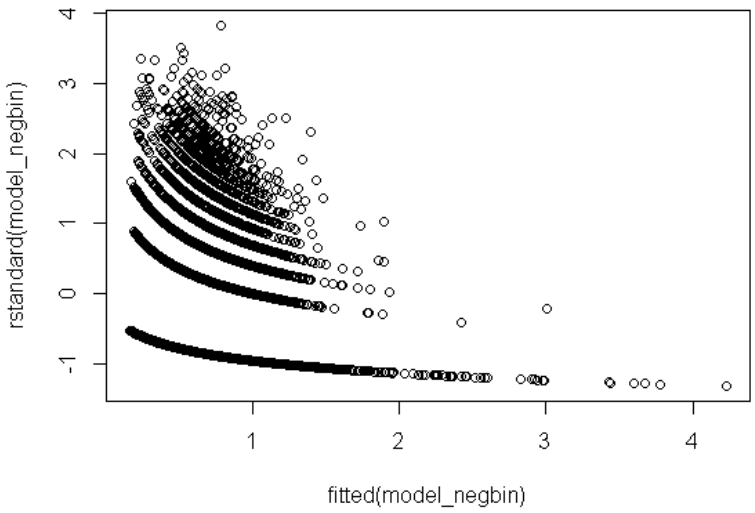
dispersion <- sum(residuals(model_negbin, type = "pearson")^2) / df.residual(
    model_negbin)
dispersion#0.9956807 NE POSTOJI OVERDISPERSION

prediction_negbin<- predict(model_negbin, newdata = test_data, type = "response"
    )

MSE(y_test, prediction_negbin)#1.61949312261325
MAE(y_test, prediction_negbin)#0.855290230564156

plot(rstandard(model_negbin)~fitted(model_negbin))
```

Kao što vidimo, vrednosti na test skupu se nisu mnogo promenile, što je dobra osobina. Na negativni binomni model ne možemo primeniti funkciju dispersion test te smo smo stoga ručno implementirali formulu koja izračunava disperziju. Dobili smo zadovoljavajuću vrednost koja je manja od 1, odakle možemo zaključiti da ne postoji pojava rasejanja u našem finalnom modelu.



Slika 11: Reziduali negativne binomne

Slično kao i u prethodnom modelu, reziduali prate gusto koncentrisane linije što je već gore pomenuto posledica neadekvatnih podataka punih kategoričkih promenljivih.

3.3.2 Predviđanje vrednosti odštete

Cilj nam je da odredimo cenu naknade za štetom koju pojedinac zatraži nakon načinjene štete. Kao model sa najboljim performansama nam se pokazao model koji koristi inverznu Gausovu raspodelu sa redukovanim brojem prediktora. U narednom delu koda, treniramo ovaj model na trening + validacionom skupu a zatim ga testiramo na test skupu.

```
#treniramo na validaciji + treningu i na samom kraju testiramo na test skupu

valid_data$avg_claim_cost<-y_valid

full_data<-rbind(train_data, valid_data)

model_invgauss_simpler <- glm(avg_claim_cost ~ Vehicle_age + Duration_of_dl,data
    = full_data, family = inverse.gaussian(link = "log"))
summary(model_invgauss_simpler)

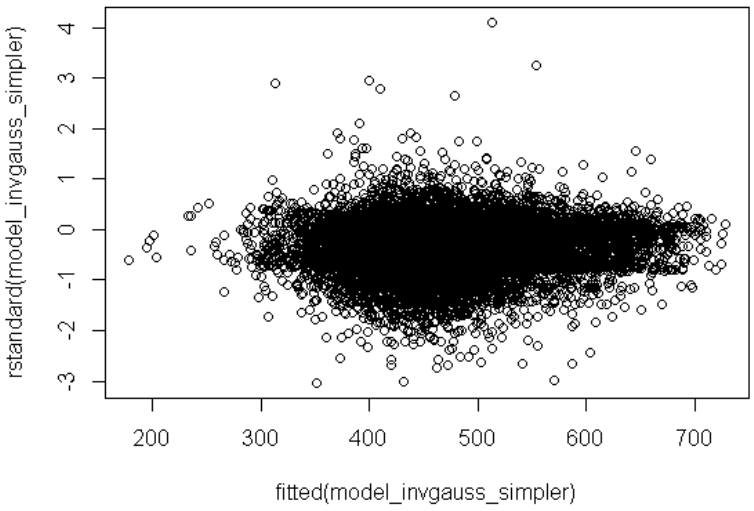
get_mae_avg_cost(model_invgauss_simpler, test_data)#469.091
get_rmse_avg_cost(model_invgauss_simpler, test_data)#976.181

plot(rstandard(model_invgauss_simpler)~fitted(model_invgauss_simpler))

dispersion <- sum(residuals(model_invgauss_simpler, type = "pearson")^2) / df.
   residual(model_invgauss_simpler)
```

```
dispersion #0.02640554
```

Nakon testiranja modela, primećujemo da su vrednosti metrika ostale poprilično iste kao na validacionom skupu. Velika prednost ovog modela se ogleda u tome što je parametar disperzije veoma mali stoga ne postoji pojava rasejanja. Sa grafika reziduala vidimo da ne postoji pojava heterskedastičnosti.



Slika 12: Reziduali inverznog Gausovog modela

4 Zaključak

Ovaj rad uspešno demonstrira efikasnost primene uopštenih linearnih modela u domenu neživotnog osiguranja, sa fokusom na procenu broja i vrednosti odšteta.

Kroz praktičnu analizu baze od preko 100.000 osiguranika smo uočili najbolje modele za predviđanje broja odšteta i vrednosti odštete. Za predviđanje broja odštete, nakon upoređivanja modela sa Puasonovom i negativnom binomnom raspodelom, zaključili smo da je model sa negativnom binomnom raspodelom bolji baš zbog nedostatka rasejanja. Za predviđanje vrednosti odštete pokazalo se da je najbolji model zapravo onaj koji koristi inverznu Gausovu raspodelu kod kog imamo redukovan broj prediktora.

Značaj primene uopštenih linearnih modela u neživotnom osiguranju, ogleda se u činjenici da su nelinearni modeli (npr. randomForest), koje smo testirali na istim podacima, dali značajno lošije rezultate, a pritom i izgubili na interpretabilnosti. Uprkos tome, postojalo je značajno ograničenje razrade teme podacima koje smo analizirali.

Za dalja istraživanja preporučili bismo prikupljanje kvalitetnijih podataka, sa naglaskom na detaljnije informacije o osiguranicima, vrstama i okolnostima nastanka šteta. Takvi podaci omogućili bi dublju analizu i potencijalno primenu složenijih uopštenih linearnih modela.

Literatura

[1] Mark Goldburd, Anand Khare, Dan Tevet, Dmitriy Guller. *Generalized Linear Models for Insurance Rating*.

[2] Tom Loeys, Beatrijs Moerkerke, Olivia De Smet, Ann Buysse. *The Analysis of Zero-Inflated Count Data: Beyond Zero-Inflated Poisson Regression*.

[3] Bojana Milošević, Blagoje Ivanović. *Linearni statistički modeli: Teorija i praktični primeri*.

[4] Samuel M. Mwalili, Emmanuel Lesaffre, Dominique Declerck. *The Zero-Inflated Negative Binomial Regression Model with Correction for Misclassification: An Example in Caries Research*.

[5] Marko Obradović. *Matematička statistika*.

[6] Esbjörn Ohlsson, Björn Johansson. *Non-Life Insurance Pricing with Generalized Linear Models*.

[7] Mario V. Wüthrich, Michael Merz. *Statistical Foundations of Actuarial Learning and Its Applications*.